90 秒项目速览

FlowLens

我用公开短视频日志，完整模拟了一次推荐分发策略迭代

从“为什么用户没有看到合适的内容”出发，我先定位供需与消费问题，再设计 4 类分发策略，最后判断它们应该上线、重测，还是停止。

发现问题 设计策略 评估取舍 给出决策

一句话结果：找到了明确的分发缺口，但没有把不确定的离线收益包装成“可以上线”。

个人项目 · 前 3 页 90 秒看懂 · 后 7 页查看方法与证据

把一次推荐策略迭代完整走通

不是只训练一个模型，而是回答业务最终要做的三个决定。

01 问题在哪里

把内容生产、曝光和消费串起来，区分“用户想看但没被分到”和“已经分到却没有消费”两类问题。

02 策略怎么改

针对问题设计协同融合、多样性、长尾探索、风险与疲劳 4 类策略，并在相同候选集上公平比较。

03 值不值得上线

同时看有效消费、重复、覆盖与负反馈。最终判断不是谁分最高，而是谁有资格进入线上 A/B。

最终交付：问题清单 + 4 类策略方案 + 冻结评估结果 + 一套线上 A/B 实验蓝图。

三个发现，决定下一步怎么做

项目的价值不是给出一个漂亮分数，而是把分析结果翻译成可执行动作。

发现 1

单一榜单会误导

同一批模型在常规曝光和随机曝光中的排名发生反转。动作：不凭一张离线榜单直接选策略。

发现 2

存在内容机会

标签 39 的需求份额比曝光份额高 5.85pp。动作：继续区分是供给不足，还是分发不足。

发现 3

收益伴随代价

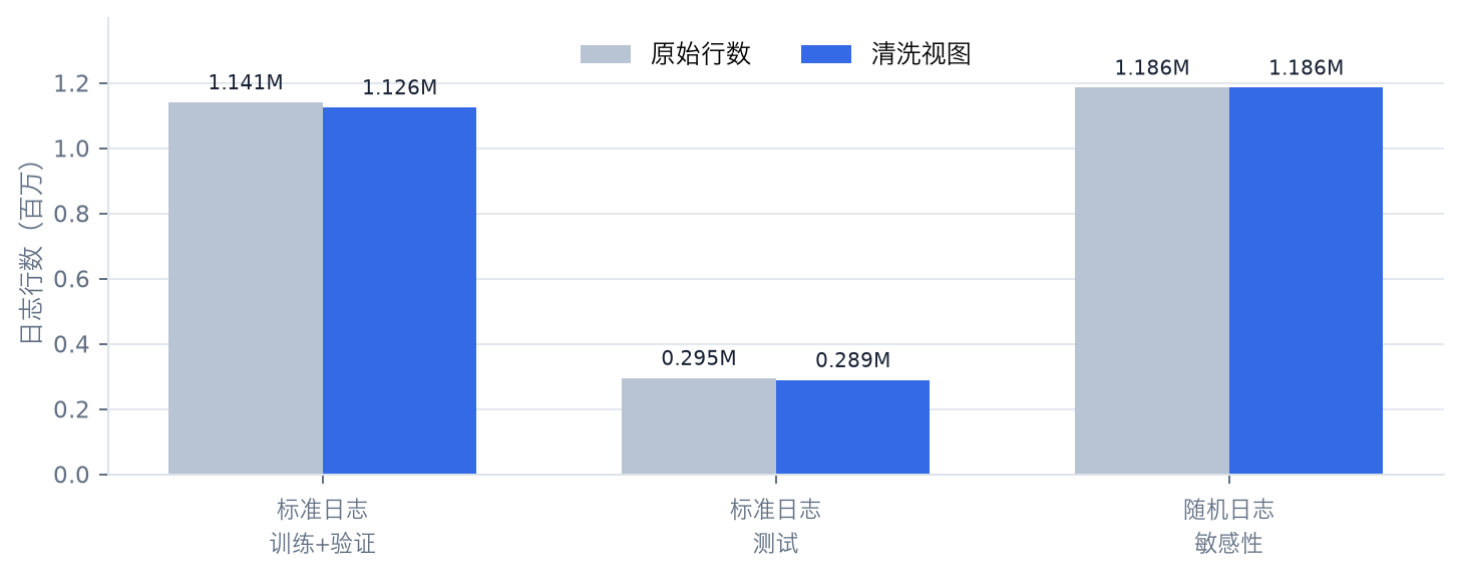
多样性策略降低了重复，但内容覆盖下降，主指标区间跨 0。动作：先调权重重测，不进入 A/B。

最终建议：保留问题方向，暂不宣称策略成功；下一轮先修复覆盖护栏，再用线上随机实验验证真实增量。

以上结论来自公开日志的离线回放，只支持发现问题与比较方案，不代表真实线上提升。

先确认数据能回答问题

在分析前处理重复、标签一致性、关联覆盖与时间可用性，避免用脏数据制造结论。



129

条 Great Expectations 规则全部通过

3 份日志

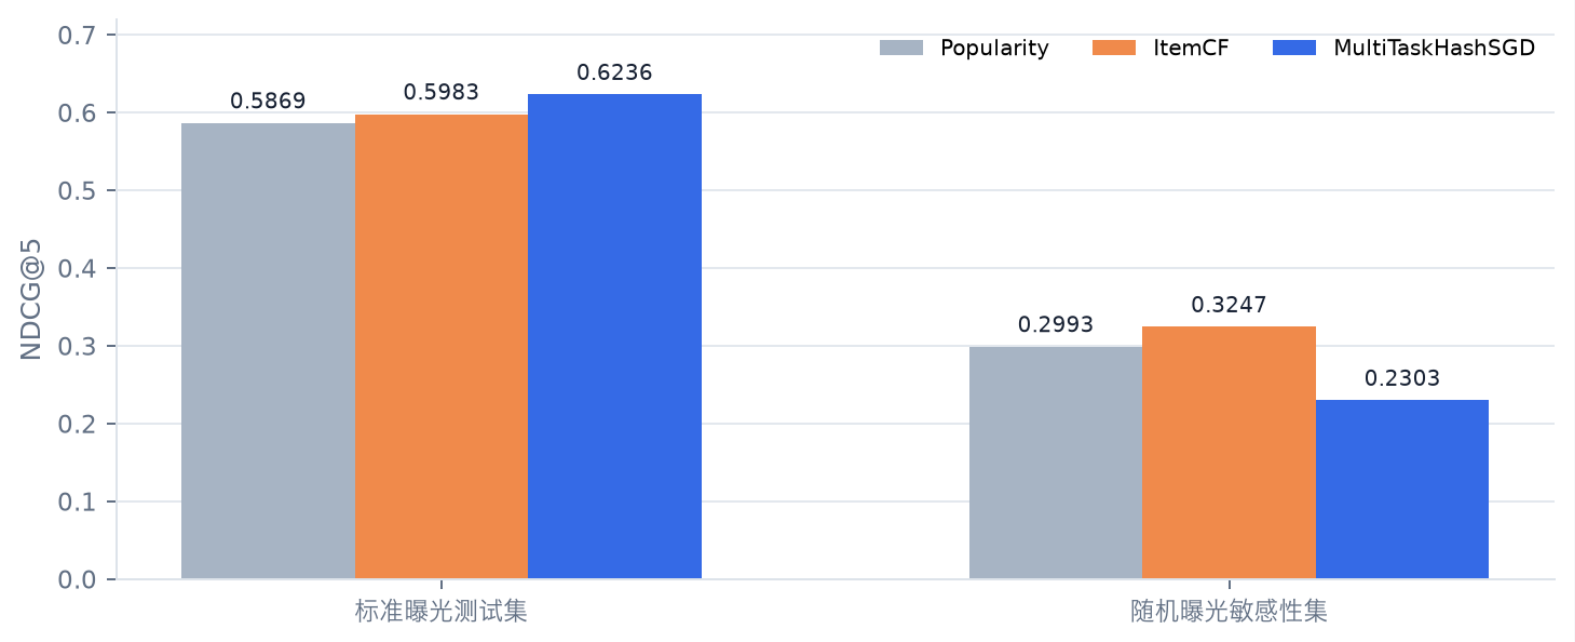
原始行保持不可变；只在分析视图删除完全重复行。

关键规则　二元标签合法 · 时间与时长非负 · is_rand 与来源一致 · 用户 / 视频外键可解析 · 结果字段与整月统计特征不得泄漏

Source: reports/data-quality/cleaning_manifest.json · gx_validation_results.json · Gate2-数据质量报告.md

同一模型，在不同流量里排名会反转

这意味着历史推荐结果会影响离线评价，不能只凭一个分数选方案。



标准曝光

MultiTask 0.6236

在已记录曝光候选上排名第一

随机曝光敏感性

ItemCF 0.3247

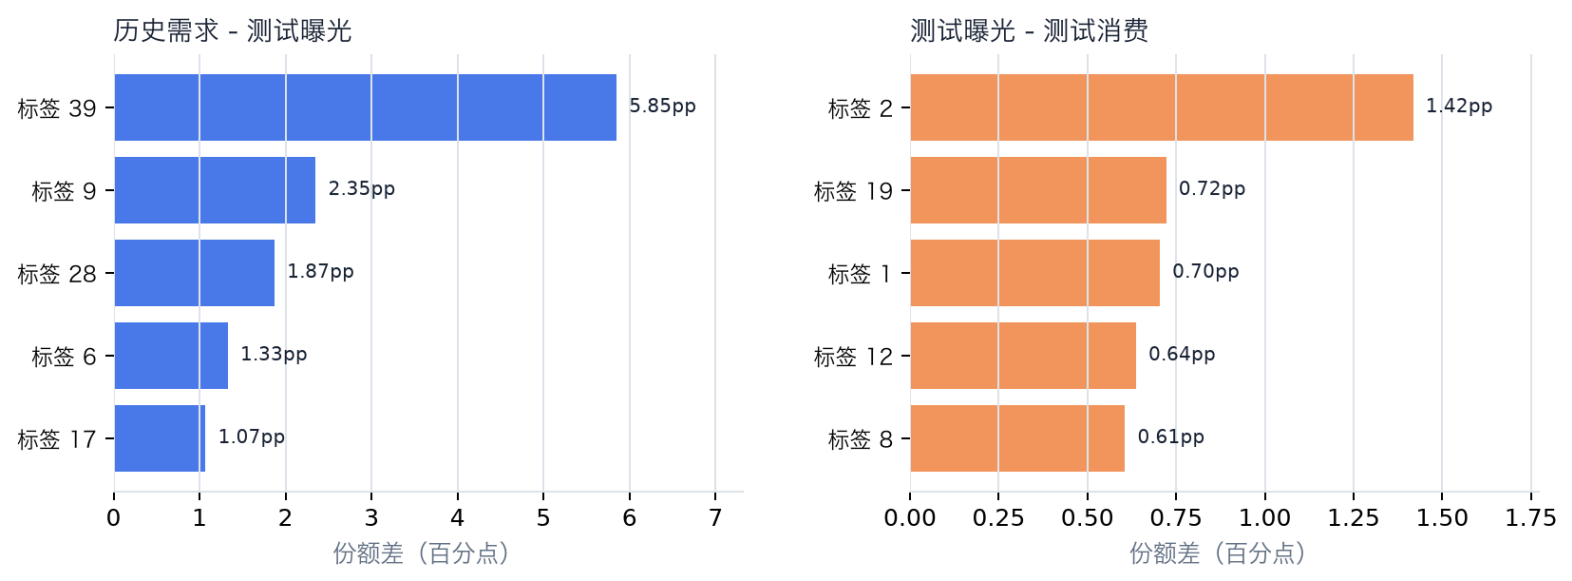
模型顺序发生反转

产品判断　不能把单一离线榜单当作普适最优；Gate 4 必须同时报告标准日志、随机日志敏感性、有效消费和生态护栏。

Source: reports/gate3/baseline_metrics.csv · Run gate3-3b42b7057a17 · 用户级 bootstrap 95% CI · E3 离线证据

找到“用户想看，却没有被充分分发”的内容机会

先用份额差找到优先级，再继续验证是供给不足、分发不足，还是人群结构差异。



标签 39

历史需求 - 测试曝光 = +5.85pp

优先拆成“补供给”与“调曝光”两个假设。

标签 2

测试曝光 - 测试消费 = +1.42pp

先按人群与 tab 下钻，再判断调配策略。

待验证，而非结论

份额差可以定位优先级，但不能证明缺口由供给不足、算法偏置或用户偏好变化造成。

Source: reports/gate3/tag_supply_demand.csv · 标签为公开数据中的 numeric ID · 份额均来自固定时间窗

针对问题，设计 4 种分发策略

先用验证数据选参数，再固定方案比较，避免为了测试结果临时调参。

S0

冻结基线

MultiTaskHashSGD

不可变快照

S1

协同融合

学习分数 + ItemCF

不可变快照

S2

多样性重排

作者 / 标签重复惩罚

不可变快照

S3

长尾探索

历史低曝光内容加权

不可变快照

S4

风险与疲劳

历史负反馈 + 作者疲劳

不可变快照

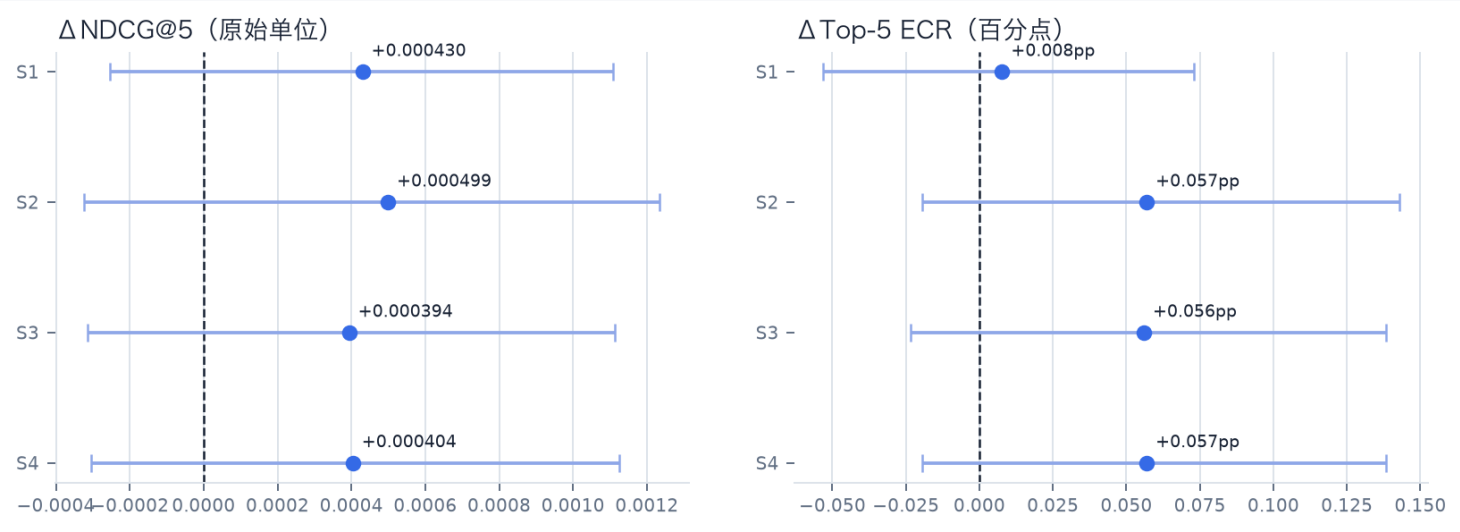
验证与决策流程

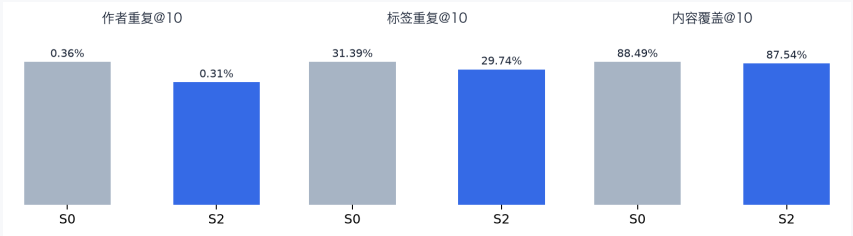
验证集选参 — 冻结策略 — 标准日志回放 — 随机日志敏感性 — 配对区间 + 护栏 — 决策门

Source: config/gate4_strategies.json · reports/gate4/strategy_snapshots.json · validation_selection.csv

一个策略看起来变好，也不能急着上线

多样性策略降低了重复，但有效消费的改善不稳定，而且内容覆盖下降。





S2 权衡　重复下降，但内容覆盖约 88.49% → 87.54%。

最终判定　S1–S4 全部 ITERATE_AND_RETEST；本轮没有策略进入线上 A/B 候选。

Source: strategy_metrics.csv · strategy_deltas.csv · offline_decisions.csv · Run gate4-c2f35eb1de6d · 300 次用户级配对 bootstrap

如果进入真实业务，我会这样验证

把离线发现变成可证伪的线上实验；本页是实验方案，不是已经执行的 A/B。

随机化与触发

- 随机化单元：用户
- 同一用户固定分组
- 触发：进入目标 Feed 且至少 2 个 eligible 候选
- assigned 与 exposed 分开记录

指标树

- 主指标：用户级有效消费率
- 互证：播放时长
- 护栏：负反馈、作者 / 内容重复、覆盖与集中度
- 收入：N/A，等待真实业务定义

实验健康

- SRM 与 A/A
- 触发率和跨组污染
- 重复事件与版本一致性
- 迟到事件与停止规则

决策规则　健康检查未通过 → 不生成效果结论；主指标区间不过门 → 继续迭代；主指标与护栏同时通过 → 才进入灰度讨论。

未执行声明：当前公开数据不足以设置真实线上 MDE、样本量与商业指标，必须在业务环境中重新预注册。

Source: reports/gate4/Gate4-线上AB实验设计.md · 本页为 E4 实验设计证据

这套项目能证明什么

价值不在于堆模型，而在于把问题、策略、评估和决策连接成闭环。

01	问题拆解	把“推荐不好”拆成供需错配、分发效率与体验生态问题
02	策略设计	针对不同问题提出协同、多样性、长尾和疲劳控制方案
03	多目标决策	不只看消费收益，同时检查重复、覆盖和负反馈代价
04	实验意识	固定评估规则，并设计从离线重测到线上 A/B 的决策门
05	边界意识	知道哪些结论有证据，哪些仍需真实业务数据验证

一句话总结

我完成的不是一个“高分模型”，而是一套能帮助业务判断下一步该做什么的推荐策略工作流。